

Федеральное государственное автономное образовательное учреждение
высшего образования

«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет бизнеса и менеджмента

Домашняя работа

По дисциплине «Временные ряды»

Выполнила:

Студентка группы МЭВ-181

Алеева Вера Александровна

Москва 2019

Вариант 40

Исходный ряд:

21.3333,22.6667,27.8294,30.4124,32.9520,14.2640,28.8415,27.8419,53.2665,19.1559,16.7668,55.6615,35.6406,30.3929,50.3441,40.2123,28.7693,33.9378,58.5428,44.5764,49.3091,50.4247,41.9638,62.7497,56.3852,41.9907,61.1028,58.6780,73.2081,66.2684,54.4457,67.6482,56.9542,64.9572,69.7775,61.5698,84.9554,57.4548,58.0847,88.6711,75.2904,79.9606,70.9618,83.2560,85.7562,76.4391,77.6164,85.2613,104.0068,74.5042,86.8909,94.7717,103.2406,100.7451,97.0038,78.8327,96.9834,102.6197,98.0549,83.8813,111.9083,118.8757,94.5341,105.2204,115.1087,119.6549,104.8529,107.0710,129.1234,109.7078,106.9881,139.7480,101.7890,103.0492,130.6339,114.8879,126.8285,126.5739,125.0049,143.9181,111.3871,139.3483,131.1971,139.8066,134.0294,131.5055,138.3898,130.1479,142.5471,151.6323,143.3908,134.7999,151.3457,147.6873,143.3519,151.3348,143.1829,160.5847,147.4983,163.1111,154.0063,155.9284,150.6340,185.3708,156.5745,161.2122,160.3083,164.8771,149.9788,186.9586,174.4658,157.6656,166.4182,185.9162,175.4570,180.4779,183.1741,179.0722,176.4521,182.3102,180.6805,192.9606,166.6624,196.1941,204.3302,166.0524,197.4435,203.4331,182.9194,199.0849,195.7082,192.6015,182.5659,198.6555,192.8288,200.6871,203.5176,204.4451,199.6403,193.4589,216.7572,202.2302,214.3964,220.0236,206.6291,198.8249,207.9889,231.3487,210.9570,215.7860,217.7013,217.5601,235.6657,211.7818,237.4417,227.7584,235.0806,218.3528,230.5214,246.4117,227.7168,210.6495,264.0180,237.5281,251.9805,235.9781,247.4135,230.6109,243.7570,256.7107,252.7107,233.9085,269.4156,247.2615,240.1998,246.4124,267.3122,258.3539,256.3502,252.6688,262.7675,257.0177,269.8386,262.4560,267.8276,273.2983,258.8461,282.0778,265.0453,261.5477,273.9821,277.2504,283.9545,268.6449,280.3142,285.1080,282.3552,299.6049,286.6788,264.3836

Задания:

1. Используя процедуру Доладо-Дженкинса-Сосвилла -Риверо, выяснить, относится ли наблюдаемый ряд к типу TSP.
2. Для ряда типа TSP оценить по МНК детерминированную составляющую ряда.
3. Детрендить ряд.
4. Провести идентификацию случайной составляющей ряда, выбрав в качестве базовых 2-3 подходящие модели.
5. Оценить параметры выбранных моделей.
6. Используя информационные критерии Акаике и Шварца, выбрать адекватную модель.
7. Провести диагностику остатков.
8. Построить прогноз на один шаг.

1. Для начала был построен график ряда (рис.1), на который также была нанесена линия тренда:



Рисунок 1

На основе графика можно сделать вывод, что ряд имеет четко-выраженный линейный тренд. Для определения принадлежности ряда к типу TSP или DSP проведем процедуру Доладо-Дженкинса-Сосвилла-Риверо, начиная с расширенного теста Дики-Фуллера. На данном шаге проверяется гипотеза о наличии единичного корня в модели

$$(1) x_t = \mu + \beta t + \alpha_1 x_{t-1} + \dots + \alpha_n x_{t-n} + \varepsilon_t :$$

Преобразуем модель (1) к виду:

$$(2) \Delta x_t = x_t - x_{t-1} = \mu + \beta t + \gamma x_{t-1} + \theta_1 \Delta x_{t-1} \dots + \theta_{n-1} \Delta x_{t-n+1} + \varepsilon_t,$$

где $\gamma = \sum_{i=1}^n \alpha_i - 1$, $\theta_i = -(\alpha_{i+1} + \dots + \alpha_n)$.

В данном случае проверяются гипотезы $H_0: \gamma = 0$ $H_A: \gamma < 0$

Для того, чтобы определить, сколько лагов включить в модель, рассчитаем оценки модели с максимальным числом включаемых лагов $\sqrt[3]{n}$, где n – это количество наблюдений, в данном случае равное 200.

Оценки модели с константой, трендом и 6 запаздываниями.

| | coef | std err | t | P> t |
|-------|---------|---------|--------|-------|
| const | 39.8818 | 5.289 | 7.539 | 0.000 |
| t | 2.6108 | 0.407 | 6.414 | 0.000 |
| L | -0.4679 | 0.076 | -6.360 | 0.000 |
| L^2 | -0.4260 | 0.081 | -5.249 | 0.000 |
| L^3 | -0.0961 | 0.087 | -1.097 | 0.274 |
| L^4 | 0.0093 | 0.087 | 0.105 | 0.916 |
| L^5 | -0.0014 | 0.082 | -0.017 | 0.987 |
| L^6 | -0.0112 | 0.074 | -0.151 | 0.880 |

По значению p-value видно, что значимыми оказываются только первые два лага, следовательно, далее будем использовать модель

$$(*) \Delta x_t = \mu + \beta t + \gamma x_{t-1} + \theta_1 \Delta x_{t-1}.$$

Найдем расчетное значение ADF-теста с помощью библиотеки statsmodels и встроенной функции adfuller в Python. На вход данной функции список, состоящий из значений временного ряда, указывается тип модели (с константой и трендом, с константой, без константы и без тренда), а также максимальное число лагов, включаемых в модель. В данном случае была указана модель с константой и трендом, максимальное число лагов 2. В результате были получены следующие оценки:

Расчетное значение ADF-теста: -11.780478271034044
p-value: 8.84431704233448e-19

Полученное значение статистики $\frac{\hat{\gamma}}{s.e.\hat{\gamma}} = -11.78$ сравниваем с критическим

1%: -3.4645146202692527
5%: -2.8765564361715534
10%: -2.5747745328940375

Как видно, расчетное значение теста меньше, чем критическое на всех разумных уровнях значимости, а значит H_0 отвергается, ряд относится к типу TSP и верна модель (*).

2. Оценим детерминированную составляющую ряда с помощью метода наименьших квадратов. Получаем следующие результаты:

Коэффициент при t: 1.3231866037650946
Независимый коэффициент 21.35046132160801
Коэффициент детерминации R²: 0.9838882305069662

Таким образом, получаем следующее уравнение тренда:

$$Y_t = 21,35 + 1,32 \cdot t \quad (3)$$

3. Детрендируем ряд, вычитая из него значения, полученные с помощью уравнения 1. В результате получаем ряд, представленный на графике (рис.2):




Рисунок 2.

4. Для идентификации случайной составляющей ряда, оценим значения автокорреляционной и частной автокорреляционной функции (рис.3)

Оценки АКФ: 1.0 0.30526821 -0.24707727 0.14134189 0.06739749 -0.07858409
 0.00101671 0.08155622 0.03042871 -0.20562257 0.20416172 -0.05488077
 -0.01463683 0.03931343 0.06915498 -0.05136239 -0.02189363 0.04048514
 0.05741984 -0.19091342]

Оценки ЧАКФ: 1.00000000e+00 -3.06802221e-01 -3.79413921e-01 -1.01270295e-01
 -1.88060538e-03 -1.84995495e-02 7.17560067e-04 7.22620256e-02
 1.19763206e-01 -1.45736161e-01 1.28533114e-01 -6.54746152e-02
 6.57860687e-02 4.19940481e-02 1.32527427e-01 6.08480617e-02
 3.89862017e-02 3.88801408e-02 4.89638487e-02 -1.43415866e-01]

Уровень значимости $\alpha=0.05$




Рисунок 3.

Видно, что оценки АКФ экспоненциально убывают и после второго лага попадают в доверительный интервал. На 9,10 и 19 лаге оценки автокорреляции отличны от 0, что можно считать случайностью на уровне значимости 5%. По графику ЧАКФ видно, что оценки первых двух лагов значительно отличаются от нуля, а начиная с третьего попадают в доверительный интервал. Таким образом следует предположить, что данный ряд представляет собой AR(2)-процесс.

5.Оценим модель AR(2):

| ARMA Model Results | | | | | | |
|--------------------|------------------|-------------------|----------|-------|--------|--------|
| ===== | | | | | | |
| Dep. Variable: | y | No. Observations: | 200 | | | |
| Model: | ARMA(2, 0) | Log Likelihood | -714.076 | | | |
| Date: | Tue, 26 Mar 2019 | AIC | 1434.152 | | | |
| Time: | 14:09:31 | BIC | 1444.047 | | | |
| ===== | | | | | | |
| | coef | std err | t | P> t | [0.025 | 0.975] |
| ----- | | | | | | |
| ar.L1.y | -0.4313 | 0.066 | -6.529 | 0.000 | -0.561 | -0.302 |
| ar.L2.y | -0.3842 | 0.066 | -5.844 | 0.000 | -0.513 | -0.255 |

Также возьмем еще две модели в качестве базовых.

AR(1):

| ARMA Model Results | | | | | | |
|--------------------|------------------|-------------------|----------|-------|--------|--------|
| ===== | | | | | | |
| Dep. Variable: | y | No. Observations: | 200 | | | |
| Model: | ARMA(1, 0) | Log Likelihood | -729.781 | | | |
| Date: | Tue, 26 Mar 2019 | AIC | 1463.562 | | | |
| Time: | 14:12:08 | BIC | 1470.159 | | | |
| ===== | | | | | | |
| | coef | std err | t | P> t | [0.025 | 0.975] |
| ----- | | | | | | |
| ar.L1.y | -0.3113 | 0.068 | -4.587 | 0.000 | -0.444 | -0.178 |

AR(3):

| ARMA Model Results | | | | | | |
|--------------------|------------------|---------|-------------------|----------|--------|--------|
| ===== | | | | | | |
| Dep. Variable: | y | | No. Observations: | 200 | | |
| Model: | ARMA(3, 0) | | Log Likelihood | -713.085 | | |
| Date: | Tue, 26 Mar 2019 | | AIC | 1434.170 | | |
| Time: | 14:13:08 | | BIC | 1447.364 | | |
| ===== | | | | | | |
| | coef | std err | t | P> t | [0.025 | 0.975] |
| ----- | | | | | | |
| ar.L1.y | -0.4684 | 0.071 | -6.616 | 0.000 | -0.607 | -0.330 |
| ar.L2.y | -0.4271 | 0.072 | -5.922 | 0.000 | -0.568 | -0.286 |
| ar.L3.y | -0.1001 | 0.071 | -1.411 | 0.160 | -0.239 | 0.039 |

4. Для выбора модели необходимо сравнить их показатели, а именно критерии Акайке и Шварца. Информационный критерий AIC для модели ARMA(p,q), где p и q соответствующие порядки модели, выглядит следующим образом:

$$AIC(p, q) = -2 \ln L + 2k,$$

L – максимизированное значение функции правдоподобия модели, $k = p + q + 1$. Критерий Шварца имеет вид:

$$BIC(p, q) = -2 \ln L + \ln n \cdot k,$$

n – число наблюдений. Соответственно, чем меньше значение критериев, тем лучше модель описывает процесс. Сравним информационные критерии Акайке и Шварца для выбранных моделей в Таблице 1

Таблица 1

Сравнение информационных критериев моделей

| | AIC | BIC |
|-------|---------|---------|
| AR(1) | 1465,56 | 1475,45 |
| AR(2) | 1434,15 | 1444,05 |
| AR(3) | 1436,14 | 1452,63 |

Видно, что самые низкие показатели имеет модель AR(2), следовательно выбираем ее для моделирования процесса.

5. Проведем диагностику остатков модели. График остатков представлен на рисунке 4:




Рисунок 4.

Так как применение ADF-теста предполагает, что остатки имеют нормальное распределение, проведем тест Харке-Бера. Статистика рассчитывается по формуле:

$$JB = \frac{n}{6} \left[S^2 + \frac{(K - 3)^2}{4} \right]$$

Где $S = \frac{1}{n} \sum_{i=1}^n \left(\frac{\varepsilon_i - \bar{\varepsilon}}{\hat{\sigma}} \right)^3$ – коэффициент асимметрии, $K = \frac{1}{n} \sum_{i=1}^n \left(\frac{\varepsilon_i - \bar{\varepsilon}}{\hat{\sigma}} \right)^4$ – коэффициент эксцесса, $\hat{\sigma}$ – дисперсия остатков.

$$H_0: \varepsilon_i \sim N(0; \sigma^2)$$

Тестовая статистика имеет распределение χ^2 с двумя степенями свободы. Нулевая гипотеза о нормальности распределения остатков ряда отвергается на уровне значимости 5%, если $JB > JB_{\text{крит}} = 5,9916$

K: [2.80432656]
S: [0.04653284]
JB: [0.3912443]
p-value: [0.82232289]

$JB < JB_{\text{крит}}$, следовательно H_0 не отвергается и остатки имеют нормальное распределение.

Для проверки остатков модели на коррелированность проведем тест Бокса-Пирса. Тест Бокса-Пирса проверяет гипотезу о совместном равенстве нулю всех автокорреляций временного ряда до порядка m включительно.

$$H_0: \rho_1 = \rho_2 = \dots = \rho_m = 0 \text{ (т.е. остатки не коррелированы)}$$

$$H_A: \sum_{k=1}^m \rho_k^2 > 0$$

Статистика рассчитывается по формуле

$$Q_{BP} = n \sum_{k=1}^m \hat{\rho}_k^2,$$

где n – число наблюдений, $\hat{\rho}_k$ – автокорреляция k -го порядка, m – число проверяемых лагов. Гипотеза адекватности подобранной модели отвергается на уровне значимости 5%, если $Q_{BP} > \chi^2(k - p - q)$ и p-value не превышает 5%.

Вычисляем статистику для $m=20$:

Q-расчетное Box-Pierce: [0.31874688 0.44678747 1.43253791 2.01805262
2.20085367 2.76458293
2.84826905 3.57025916 8.54828076 13.24999481 13.58384581 15.21272407
15.93178109 17.6753303 17.71117916 17.8015899 17.90467575 17.99749421
22.66742425 23.92662737]
p-value: [0.5723617 0.79979988 0.6979257 0.73243833 0.82071265 0.83776084
0.89867477 0.89366896 0.47997094 0.21002829 0.25688185 0.23000884
0.25283328 0.22197031 0.27815402 0.33564281 0.3948784 0.45581769
0.25230814 0.24561194]

Видно, что p-value для всех лагов больше 5%, а значит H_0 не отвергается и остатки не коррелированы.

6. Построим прогноз на один шаг.

Коэффициенты модели AR(2):

$$AR(1) = -0,4313 \quad AR(2) = -0,3842$$

Соответствующие значения детрендрованного временного ряда:

$$x_{200} = -21,60 \quad x_{199} = 2,014$$

Уравнение тренда:

$$Y_{201} = 21,35 + 1,32 \cdot 201$$

Прогноз для детрендрованного ряда:

$$-0,4313 * (-21,60) - 0,3842 * 2,014 = 8,544$$

Добавляем трендовую составляющую и получаем

$$x_{201} = 21,35 + 1,32 \cdot 201 + 8,544 = 295,214$$